## گزارش تمرین

# عرفان رفيعي اسكويي - 98243027

#### 1) داده های از دست رفته

در این پروژه برای اصلاح دادههای از دست رفته ابتدا تمامی سطرهایی که همه ویژگیهایش از دست رفته اند پاک میکنیم. سپس ریفتهایی که داده های از دست رفته دارند را با روش bfill پر میکنیم. با این کار تمام نمونهها دیگر مشکل ندارند.

```
Training set:
CustomerID
                          0
Age
                          0
Gender
                          0
City
State
No of orders placed
                          0
Sign up date
Last_order_placed_date
is premium member
                          0
Women's_Clothing
Men's_Clothing
                          0
Kid's Clothing
                          0
Home_&_Living
                          0
Beauty
                          а
Electronics
Preferred Theme
                          0
dtype: int64
Test set:
CustomerID
                          0
Age
Gender
                          0
City
                          0
```

#### 2) استانداردسازی:

### در این مرحله دادههای ستونهای عددی با فرایند StandardScaler نرمال میشوند. کد این مرحله:

حال نوبت به ستونهای غیرعددی و Categorical است که در این روش دادهها بصورت conehotencoder نرمال می شوند.

## 3) الگوريتم KNN

الگوریتم KNN با روش فاصله Minkowski نوشته شده است که برای هر داده نزدیک ترین همسایه آن معرفی می شود. با این الگوریتم مقددار دقت برای داده validation برابر با 63 درصد است.

```
distances.append(distance)
         df_dists = pd.DataFrame(data=distances, columns=['dist'],
                               index=y_train.index)
         df_nn = df_dists.sort_values(by=['dist'], axis=0)[:k]
         # Create counter object to track the labels of k closest neigh
         counter = Counter(y train[df nn.index])
         # Get most common label of all the nearest neighbors
         prediction = counter.most_common()[0][0]
         # Append prediction to output list
         y_hat_test.append(prediction)
     return y hat test
 y hat test = knn predict(X train.values, X val.values, y train, y val,
 print(accuracy_score(y val, y hat test))
  Python
.6360207449316361
```

4) حال با روشهای دیگر مقدار دقت را بر روی دادههای مشخص شده بدست می آوریم. روش اول Decision Tree، روش دوم SVC و روش سوم RandomForest است.

```
############## YOUR CODE STARTS HERE ################
   from sklearn import tree
   from sklearn import svm
   from sklearn.ensemble import RandomForestClassifier
   #DecisionTreeClassifier
   clf = tree.DecisionTreeClassifier()
   clf = clf.fit(X_train.values, y_train.values)
   y_hat_test_DT = clf.predict(X_test.values)
   print('DecisionTreeClassifier: ',accuracy_score(y_test, y_hat_test_DT)
   clf = svm.SVC()
   clf = clf.fit(X train.values, y_train.values)
   y_hat_test_SVC = clf.predict(X_test.values)
   print('SVC: ',accuracy_score(y_test, y_hat_test_SVC))
   #RandomForestClassifier
   clf = RandomForestClassifier(n estimators=10)
   clf = clf.fit(X_train.values, y_train.values)
   y_hat_test_RF = clf.predict(X_test.values)
   print('RandomForestClassifier: ',accuracy_score(y_test, y_hat_test_RF)
   Python
DecisionTreeClassifier: 0.5991199119911991
SVC: 0.6941694169416942
RandomForestClassifier: 0.6664466446644665
```

5) ارزیابی

در این مرحله برای دادههای تست مقدار Recall ،Precision ،Accuracy و F1-Score را بدست می آوریم.

```
from sklearn.metrics import precision_recall_fscore_support
#DecisionTreeClassifier
precision,recall,fscore,support = precision_recall_fscore_support(y_te
print('precision for each label (DecisionTreeClassifier): ',precision)
print('recall for each label (DecisionTreeClassifier): ',recall)
print('fscore for each label (DecisionTreeClassifier): ',fscore)
print('support for each label (DecisionTreeClassifier): ',support)
print('----')
#SVC
precision.recall.fscore.support = precision recall fscore support(y te
print('precision for each label (SVC): ',precision)
print('recall for each label (SVC): ',recall)
print('fscore for each label (SVC): ',fscore)
print('support for each label (SVC): ',support)
print('----')
#RandomForestClassifier
precision,recall,fscore,support = precision_recall_fscore_support(y_te
print('precision for each label (RandomForestClassifier): ',precision)
print('recall for each label (RandomForestClassifier): ',recall)
print('fscore for each label (RandomForestClassifier): ',fscore)
print('support for each label (RandomForestClassifier): ',support)
```

ъ.,

```
precision for each label (DecisionTreeClassifier): [0.92450331 0.91622807]
recall for each label (DecisionTreeClassifier): [0.91641138 0.92433628]
fscore for each label (DecisionTreeClassifier): [0.92043956 0.92026432]
support for each label (DecisionTreeClassifier): [2285 2260]

precision for each label (SVC): [0.72904762 0.69161554]
recall for each label (SVC): [0.67002188 0.74823009]
fscore for each label (SVC): [0.69828962 0.71880978]
support for each label (SVC): [2285 2260]

precision for each label (RandomForestClassifier): [0.90752417 0.94182825]
recall for each label (RandomForestClassifier): [0.92581475 0.92182558]
support for each label (RandomForestClassifier): [0.92581475 0.92182558]
support for each label (RandomForestClassifier): [2285 2260]
```